

Сравнение трансформера и градиентного бустинга в задаче кредитного скоринга

Автор:

Царев Иван Николаевич,
ФПМИ, Б05-103

Научный руководитель:

Филлипенков Николай Владимирович

Кредитный скоринг - оценка платежеспособности клиента на основе множества признаков.

Новизна:

Если нейросети изменили подход к обработке изображений и текстов, почему табличные данные до сих пор остаются территорией градиентного бустинга?

В этой работе я покажу, что современные нейросетевые архитектуры при правильной адаптации способны не только конкурировать с градиентным бустингом в задаче кредитного скоринга, но и превосходить его по качеству.

ЦЕЛЬ


- 01** Исследовать и реализовать современные нейросетевые архитектуры и методы токенизации данных (эмбединг).
- 02** Провести эксперименты на нескольких публичных датасетах по кредитному скорингу.
- 03** Сравнить качество нейросетевых моделей с градиентным бустингом и доказать их конкурентоспособность.

История скоринга




Градиентный бустинг

- ✓ Дает лучшее качество
- ✓ Не требует много вычислительных ресурсов
- ✓ Быстро обучается
- ✓ Легок в использовании
- ✗ Ручное создание признаков
- ✗ Не работает с последовательными данными






Нейронные сети

- Хорошо работают с различными признаками ✓
- Не требуют ручного добавления признаков ✓
- Возможность дообучения на новых данных ✓
- Требуется GPU и долго обучается ✗
- Нужно продумывать архитектуру и продумывать гиперпараметры ✗




■ Бейзлайны ■ Табличные нейросети






“Self-Normalizing Neural Networks”, Klambauer, 2017

Применение Transformer к табличным данным




FT-Transformer



Эмбединг — важный компонент нейросетей, преобразующий категориальные и числовые признаки в плотные векторы. Это упрощает обработку данных моделью и улучшает качество обучения.

Современные исследования показывают, что эмбединги повышают эффективность моделей, особенно при работе с данными высокой размерности.

Пример эмбединга для 3-х численных и 2-ух категориальных признаков




Кусочно-линейное кодирование

$$\text{PLE}(x) = [e_1, \dots, e_T] \in \mathbb{R}^T$$

$$e_t = \begin{cases} 0, & x < b_{t-1} \text{ и } t > 1 \\ 1, & x \geq b_t \text{ и } t < T \\ \frac{x - b_{t-1}}{b_t - b_{t-1}}, & \text{иначе} \end{cases}$$

Построение решающего
дерева по одному признаку



Перцентили


$$b_t = Q_t \left(\left\{ x_i^{(j)} \right\}_{j \in J_{train}} \right)$$

где Q - это функция
получения квантиля


Фурье-кодирование (периодические фичи)

$$f_i(x) = \text{Periodic}(x) = \text{concat}[\sin(v), \cos(v)] \quad \forall v = [2\pi c_1 x, \dots, 2\pi c_k x]$$

MLP-encoder Transformer



MLP_encoder_Transformer



ROC-AUC на валидационном
датасете

Модель	HDCR	HCR	CSC
MLP	0.738	0.731	0.925
ResNet	0.723	0.703	0.915
FT-Transformer	0.748	0.742	0.926
CatBoost	0.761	0.75	0.939

MLP модель с использованием
различных эмбедингов

Энкодер	HDCR	HCR	HDCR
Without Encoder	0.738	0.744	0.931
PereodicEncoder	0.712	0.683	0.932
PiecewiseLinerEncoder	0.752	0.753	0.917
ElementWiseMultiplEncoder	0.72	0.712	0.896

ROC-AUC на валидационном датасете
с эмбедингами

Модель	HDCR	HCR	CSC
PLE-encoder MLP	0.753	0.745	0.925
PLE-encoder ResNet	0.727	0.729	0.920
PLE-encoder Transformer	0.758	0.756	0.943
MLP-encoder Transformer	0.733	0.743	0.928
CatBoost	0.761	0.750	0.939

GitVerse



Диплом

